

Adapting and Evaluating Formative L2 Comprehensibility Assessment Scale

Aki Tsunemoto, Rie Koizumi, Makoto Fukazawa,
Yo In'nami, Ryo Maie, Mariko Abe

The 46th Language Testing Research Colloquium (LTRC 2025)

Bangkok, Thailand

June 7th, 2025



What is comprehensibility?

- Ease/difficulty of understanding second language (L2) speech (Derwing & Munro, 2015)
- Reflects listeners' understanding (Kennedy & Trofimovich, 2019)
- Key aspect of L2 oral proficiency that aids effective communication (Saito & Plonsky, 2019)
- Influenced by various linguistic factors, such as phonological, temporal, lexical, and grammatical features (e.g., Isaacs & Trofimovich, 2012)
- Featured in rubrics of various language assessment scales (e.g., TOEFL, IELTS, CEFR)

Measurements of comprehensibility

- Likert-type scales (e.g., *hard to understand – easy to understand*; e.g., Munro & Derwing, 1995); semantic differential scales
- Capture listeners' impressionistic judgements of L2 speech
- Possible issues with speech perception scales:
 - need to minimize construct-irrelevant variance in assessment
 - L2 learners often lack understanding of their comprehensibility levels and how to improve comprehensibility

Using rubrics to evaluate L2 comprehensibility

- Isaacs, T., Trofimovich, P., & Foote, J. A. (2018). Developing a user-oriented second language comprehensibility scale for English-medium universities. *Language Testing*, 35, 193–216.
- <https://osf.io/svbfp/>

Article

LANGUAGE
TESTING

Developing a user-oriented second language comprehensibility scale for English-medium universities

Talia Isaacs

University of Bristol, UK

Pavel Trofimovich

Concordia University, Canada

Jennifer Ann Foote

Concordia University, Canada

Language Testing
1–24

© The Author(s) 2017

Reprints and permissions:

sagepub.co.uk/journalsPermissions.nav

DOI: 10.1177/0265532217703433

journals.sagepub.com/home/ltj



Isaacs et al. (2018)

- **Goal:** development of evidence-based rubrics for formative assessment of L2 comprehensibility
- **Raters:** Canada and UK-based EAP teachers
- **L2 speakers:** mixed L1s
- **Tasks:** picture narration, graph description, long-turn IELTS-type task, TOEFL-type integrated speaking tasks
- **Iterative process:** 5 focus groups over 12 sessions

Overall description of comprehensibility (1 = low comprehensibility; 5 = high comprehensibility)

COMPREHENSIBILITY LEVEL	OVERALL DESCRIPTION OF COMPREHENSIBILITY (Summary Statement)
5	Speech is effortless to understand Errors, are rare and do not interfere with the message **Sounding nativelike or producing hesitation- or error-free speech is <i>not</i> necessary to achieve a level 5 (highest level)
4	Speech requires little effort to understand Errors minimally interfere with the message
3	Speech requires some effort to understand Errors somewhat interfere with the message
2	Speech is effortful to understand Errors are detrimental to the message
1	Speech is painstakingly effortful to understand or indecipherable Errors are debilitating to the message **Not enough <i>comprehensible</i> language is generated for coherent communication, confining the speaker to level 1
UR	Unable to Rate the speech No assessable speech sample is produced (e.g., unresponsive to the task, no articulation of English-like sounds)

COMP	PRONUNCIATION	FLUENCY	VOCABULARY	GRAMMAR
5	- pronunciation is effortless to understand - errors do not interfere with the message	- fluent speech, which is optimally paced, is effortless to understand - hesitation markers are used at appropriate junctures or strategically	- precise lexical choice relevant to the task is effortless to understand - errors do not interfere with the message - nuanced idiomatic expressions may be used,	- grammatical use conveys precise meaning or nuance, resulting in speech that is effortless to understand - errors do not interfere with the message
4	- pronunciation is effortless to understand - errors do not interfere with the message	- fluent speech, which is optimally paced, is effortless to understand - hesitation markers are used at appropriate junctures or strategically	- precise lexical choice relevant to the task is effortless to understand - errors do not interfere with the message - nuanced idiomatic expressions may be used,	- grammatical use conveys precise meaning or nuance, resulting in speech that is effortless to understand - errors do not interfere with the message
3	- pronunciation is effortless to understand - errors do not interfere with the message	- fluent speech, which is optimally paced, is effortless to understand - hesitation markers are used at appropriate junctures or strategically	- precise lexical choice relevant to the task is effortless to understand - errors do not interfere with the message - nuanced idiomatic expressions may be used,	- grammatical use conveys precise meaning or nuance, resulting in speech that is effortless to understand - errors do not interfere with the message
2	- pronunciation is effortless to understand - errors do not interfere with the message	- fluent speech, which is optimally paced, is effortless to understand - hesitation markers are used at appropriate junctures or strategically	- precise lexical choice relevant to the task is effortless to understand - errors do not interfere with the message - nuanced idiomatic expressions may be used,	- grammatical use conveys precise meaning or nuance, resulting in speech that is effortless to understand - errors do not interfere with the message
1	- pronunciation is effortless to understand - errors do not interfere with the message	- fluent speech, which is optimally paced, is effortless to understand - hesitation markers are used at appropriate junctures or strategically	- precise lexical choice relevant to the task is effortless to understand - errors do not interfere with the message - nuanced idiomatic expressions may be used,	- grammatical use conveys precise meaning or nuance, resulting in speech that is effortless to understand - errors do not interfere with the message
UR	Unable to Rate. Speaker does not produce an assessable sample of speech (e.g., unresponsive to the task, no articulation of English-like sounds)			

Current study

- Using rating rubric to evaluate L2 comprehensibility
- Introducing training to improve reliability and validity of ratings (Kang et al., 2019)
- Japanese EFL context
 - comprehensibility has been promoted as classroom performance evaluation criteria (National Institute for Educational Policy Research, 2021) but lacks clear evaluation guidelines

To what extent the rating rubric can reliably evaluate Japanese secondary school students' L2 comprehensibility?

Speech files

- Drawn from existing speech corpus (Abe & Kondo, 2019)
- 104 L1 Japanese secondary school students (age 15–17)
- L2 proficiency: CEFR A1 to B1
- ***Telephone Standard Speaking Test*** (TSST: <https://tsst.alc.co.jp/biz/en/>)
 - responding to prompt question on phone call (no planning; 45-sec)
 - monologues with varied tasks (e.g., describing events, giving reasons)
 - topics included seasons, school, food, etc.
 - each student recorded 10 speech files across 7 sessions
- Purposefully selected wide range of performances (TSST levels 2–7: widest in corpus)

Rating rubric (translated into Japanese)

- **Holistic** (6-level): comprehensibility
- **Analytic** (6-level) : pronunciation, fluency, vocabulary, grammar
 - Level 0 = unable to rate the speech

理解しやすさの総合的尺度（1 = 理解しやすさが低い、5 = 理解しやすさが高い）	
理解しやすさのレベル	理解しやすさの全体的な説明（要約）
5	スピーチを理解するのが非常に容易（全く努力を要さない） 誤りは稀であり、メッセージに影響を与えない **レベル5（最高レベル）に到達するためには、母語話者のように聞こえたり、ためらいや誤りのないスピーチをししたりする必要はない
4	スピーチは理解するのにほとんど努力を要さない 誤りはメッセージにほとんど影響を与えない
3	スピーチは理解するのに多少の努力を要する 誤りはメッセージにいくらか影響を与える
2	スピーチは理解するのが困難 誤りはメッセージに悪い影響を与える
1	スピーチは理解するのが非常に困難、または理解不可能 誤りはメッセージに非常に悪い影響を与える **筋の通ったコミュニケーションを行うのに必要な、理解可能な言葉がほとんど話されない場合、話し手はレベル1と評価される
0 （評価不可能）	スピーチは評価できない 評価可能なスピーチが話されない（例：タスクに無反応、英語らしい発音がない）

理解しやすさの分析的尺度				
	発音	流暢さ	語彙	文法
5	- 発音は理解するのが非常に容易（全く努力を要さない） - 誤りはメッセージに影響を与えない - ピッチ（音の高低）の変化により、スピーチが生き生きと、または興味深く聞こえることがある - 母語話者のような発音は期待されない	- スピーチは流暢で、かつ最適な速度で、理解するのが非常に容易（全く努力を要さない） - ためらいのマーカークャップは、注意を継続して引きつけるために、適切な箇所や、または戦略的に使用される	- 語彙の選択は、正確でタスクに関連しており、理解するのが非常に容易（全く努力を要さない） - 誤りはメッセージに影響を与えない - タスクによっては、繊細なイディオム表現が見られることがある	- 文法の適切な使用により、正確な意味やニュアンスを伝え、スピーチを理解するのが非常に容易（全く努力を要さない） - 誤りはメッセージに影響を与えない - タスクによっては、複雑な文が使用されることがある
4	- 発音は理解するのにほとんど努力を要さない - 誤りはメッセージにほとんど影響を与えない - ピッチの変動が多すぎる、または少なすぎるため、スピーチが切れ切れに、または単調に聞こえることがある	- スピーチはやや速すぎるか遅すぎる場合があるが、ほとんど流暢で、理解するのにほとんど努力を要さない - ためらいのマーカークャップは、基本的に適切な箇所で使用される	- 語彙の選択は、満足のいくものでタスクに関連しており、理解するのにほとんど努力を要さない - 誤りはメッセージにほとんど影響を与えない - 通常ではない、またはあまり馴染みのない語彙表現が使用されることがある	- 文法のおおむね適切な使用により、正確な意味を伝え、スピーチを理解するのにほとんど努力を要さない - 誤りはメッセージにほとんど影響を与えない - 単純な文と複雑な文が両方使用される
3	- 発音は理解するのに多少の努力を要する - 誤りはメッセージにいくらか影響を与える（参考にする観点の例：語のストレス位置の誤り、音の置換、文中の重要な語にストレスを置かない）	- スピーチは速すぎるまたは遅すぎる場合があるが、やや流暢で、理解するのに多少の努力を要する - ためらいのマーカークャップは、時折不適切な箇所で使用される	- 語彙の選択は単純で、理解するのに多少の努力を要する - 誤りはメッセージにいくらか影響を与える - 語彙のギャップが時折あり、やや理解に苦勞を要するスピーチだが、意味は大まかに伝わる	- 文法のときどき不適切な使用により、大まかな意味は伝わるが、スピーチを理解するのに多少の努力を要する - 誤りはメッセージにいくらか影響を与える - 複雑な文の代わりに、より単純な文が使用される
2	- 発音は理解するのが困難 - 誤りはメッセージに悪い影響を与える（参考にする観点の例：語のストレス位置の誤り、音の置換、文中の重要な単語にストレスを置かない） - 発音の問題が数語の意味を不明にすることがある	- スピーチは速すぎまたは遅すぎ、あまり流暢でなく、理解するのが困難 - ためらいのマーカークャップは頻繁に不適切な箇所で使用される - 流暢さのギャップを補うために方略が使用される（例：アイディアが回りにくく説明される、自己修正）	- 語彙の選択は限定的で、頻繁な語彙の誤りのために理解するのが困難 - 誤りはメッセージに悪い影響を与える - 語彙のギャップは頻繁にあり、スピーチの理解に苦勞を要する、または情報不足になることがある - 限られた語彙を補うために、定型表現を使って切り替えることがある	- 文法の不適切な使用により、意味が曖昧になることがあり、スピーチを理解するのが困難 - 誤りはメッセージに悪い影響を与える - 基本的な文構造のみが使用される
1	- 発音は理解するのが非常に困難 - 誤りはメッセージに非常に悪い影響を与える（参考にする観点の例：語のストレス位置の誤り、音の置換、文中の重要な単語にストレスを置かない） - 発話の困難さにより、語が口ごもって聞こえる、または不明瞭に聞こえることがある	- スピーチはあまりに速すぎまたは遅すぎ、非流暢で、理解するのが非常に困難 - ためらいのマーカークャップは、非常に頻繁に不適切な箇所で使用され、たどたどしく片言のスピーチになる - 流暢さのギャップを補うために方略が使用されない	- 語彙の選択は、極度に単純または限られており、非常に頻繁な語彙の誤りのため、理解するのが非常に困難 - 誤りはメッセージに非常に悪い影響を与える - 語彙のギャップは頻繁にあり、スピーチが情報不足で、理解できないことがある - 限られた語彙を補うために、語彙の固まりは使用されない	- 文法の非常に不適切な使用により、意味が曖昧になり、スピーチを理解するのが非常に困難 - 誤りはメッセージに非常に悪い影響を与える - 非常に基本的な文または語句のみが使用される
0	評価不可能：話し手は評価可能なスピーチを話さない（例：タスクに無反応、英語らしい発音がない）			

Procedure

Pilot Study

Initial
testing with
5 raters

Data Analysis & Discussion

Analyze pilot
results &
identify issues



Pilot study

- **Raters ($n = 5$):**
 - university instructors who regularly evaluate Japanese students' L2 speech
- **Speech files:** 50 audio files drawn from the corpus
 - first author rated files to ensure variability in comprehensibility and related features (no rater training)
 - counter-balanced for presentation
- **Post-rating discussion:**
 - 5 raters discussed experience using scales for speech assessment
- **Consistent scoring yet significant variations among raters**
 - Exact = 34.5% < Expected = 36.7%

Procedure

Pilot Study

Initial
testing with
5 raters

Data Analysis & Discussion

Analyze pilot
results &
identify issues

Rubric Revision

Rubric revised
in response to
findings



Revised rubric

- Scale revision scheme (Knoch et al., 2021):
 - (a) performance samples, (b) previous studies (e.g., Kahng, 2018), (c) comments from experts

1. Added pauses

- hesitation markers **and pauses** are used at appropriate juncture...


2. Added explanation

- **features to take into account**: e.g., misplaced word stress, sound substitution...

3. Revised expressions for appropriateness of grammatical use

- appropriate, *mostly* appropriate, *sometimes* inappropriate, inappropriate, *extremely* inappropriate

Procedure



Main study – Raters

- **L1 Japanese teachers** ($n = 25$, 11 female; $M_{age} = 45$, $range = 26–61$)
- **School levels:** 1 junior high, 12 senior high, 12 university teachers
- **English teaching experience:** $M_{years} = 17.44$, $range = 3–39$
- **Study abroad experience:** 68% had studied abroad
- **English proficiency:** CEFR B2–C1
- **Japanese-accented English familiarity:** $M = 80\%$, $range = 30–100$

Introduction

- Introduced speech corpus
- Introduced rating criteria:
 - definitions
 - points of reference
 - rationales and examples

流暢さ

次に、流暢さ（りゅうちょうさ）を評価します。

スピーチがどれだけ「なめらかか」の観点で、速度、ためらいのマーカ（hesitation marker）やポーズ（pause）の頻度や位置、言い直しなどから多角的に判断してください。

以下、具体例とともに採点のポイントを解説します。

スピーチの速度

スピーチは速すぎても遅すぎても理解に負担をかけます。

ポーズやためらいのマーカ（hesitation marker）の頻度・位置

ためらいのマーカ（hesitation marker）の例：“well,” “I think,” “I mean,” “let me see,” “you see,” “you know,” “mm,” 「えー」、「あー」。

ためらいのマーカやポーズが多い・長いと理解に負担がかかります。

ためらいのマーカやポーズは、位置によって適切さが変わるといわれています。考えをまとめるために文と文、節と節の間で使用される場合、適切な使用と考えられます；一方で、文中や節内（例：“I ... take ... a bath”）での使用は不適切と考えられます。

流暢さのギャップ（gaps in fluency）を補う方略

流暢さのギャップ、つまり言いたいことが流暢に言えないことを克服するために、周りくどい言い方をしたり、自己修正（言い直し、言いかけてやめる）する場合があります。

*一貫して、流暢さとはいわゆる熟達度ではなく、言葉の流れ・発話がどれだけスムーズだったかという観点です。その観点から、理解しやすさについて評価してください。

	流暢さ
5	- スピーチは流暢、かつ最適な速度で、理解するのが非常に容易（全く努力を要さない） - ためらいのマーカやポーズは、注意を継続して引きつけるために、適切な箇所、または戦略的に使用される
4	- スピーチはやや速すぎるか遅すぎる場合はあるが、ほとんど流暢で、理解するのはほとんど努力を要さない - ためらいのマーカやポーズは、基本的に適切な箇所で使用される
3	- スピーチは速すぎるまたは遅すぎる場合はあるが、やや流暢で、理解するのに多少の努力を要する - ためらいのマーカやポーズは、時折不適切な箇所で使用される
2	- スピーチは速すぎるまたは遅すぎ、あまり流暢でなく、理解するのが困難 - ためらいのマーカやポーズは頻繁に不適切な箇所で使用される - 流暢さのギャップを補うために方略が使用される（例：アイディアが固くどく説明される、自己修正）
1	- スピーチはあまりに速すぎるまたは遅すぎ、非流暢で、理解するのが非常に困難 - ためらいのマーカやポーズは、非常に頻繁に不適切な箇所で使用され、たどたどしく片言のスピーチになる - 流暢さのギャップを補うために方略が使用されない

Rating practice



- Listen to 10 audio files
 - comprehensibility levels 1– 5* 2
 - used only for practice; different topics
- Rubric was prepared as separate PDF
- Listened to each speech up to 2 times (Kermad, 2024)

実際に音声聞いて採点練習 (5)

スピーチを聞いて、以下の観点について採点してください:
理解しやすさ・発音・流暢さ・語彙・文法

▶ 0:00 0:45

理解しやすさ	発音	流暢さ	語彙	文法
☐ 5	☐ 5	☐ 5	☐ 5	☐ 5
☐ 4	☐ 4	☐ 4	☐ 4	☐ 4
☐ 3	☐ 3	☐ 3	☐ 3	☐ 3
☐ 2	☐ 2	☐ 2	☐ 2	☐ 2
☐ 1	☐ 1	☐ 1	☐ 1	☐ 1
☐ 0	☐ 0	☐ 0	☐ 0	☐ 0

▶ 0:00 0:45

必要ならば、同じ音声をもう一度聞けます

Next

Calibration and benchmark ratings

- Explanation provided immediately after rating each file
- Transcript and audio for replay
- Introduced benchmark scores and rationales for assigned ratings with specific examples
- Rating training took about 20 min

採点練習（５）：モデル採点例と採点理由

５つの観点それぞれについて、採点例とその理由をご紹介します

I usually go to the barber who is the my my mother's friend. Aa I went I've been there for um ah maybe more than ten ten years I guess and also she is very good at talking um while cutting my hair she talked ah she talked a lot and also I'm so ha I'm I can enjoy while ah cutting my hair and also aa she is very aa she is good at cutting. So my hair style is always good after she cutting my ha cut after she cut. So aa I I I can go there without any worries and also I'm.

▶ 0:00 0:45

理解しやすさ ５：言い直しや文法の間違い、音の置換などはあるが、どれもメッセージの妨げにならず、理解するのが非常に容易。

発音 ４：基本的に発音の理解に努力は要さないが、一部音の置換がある（例：there /zeer/ ; very /beri/）。

流暢さ ５：流暢かつ最適な速度、自己修正は適切な語句への言い換えのために使用、ためらいのマーカ（例：I guess）も戦略的に使用。

語彙 ５：語彙の使用は正確でタスクに関連している。基本的に誤りはなく、語彙の固まりを自然に用いている（例：without any worries）、barberなどタスクにあった、通常でない語彙も使用している。

文法 ５：文法の誤りはあるが（例：時制の一致 she talked/I can enjoy/she is、三人称単数after she cut）、メッセージの妨げにならない。複雑な文（例：barber who is...; while ...-ing）も使用している。

Next

Independent ratings

- 50 audio files
 - audio files were uniquely randomized for each rater
- Raters had chance to ask questions
- Instructed to use headphones in quiet setting, securing about 2 hours without distraction
- Background questionnaires and post-rating survey to share rating experience

Data analysis

- Many-facet Rasch measurement, using Facets
- (+ questionnaire analysis)
- Partial credit model
- 50 students x 26 raters (25 raters + model rating) x 5 criteria (holistic + analytic)
- Initial analysis: 1 underfitting rater (both strict and lenient)
 - Low proficiency and low accent familiarity
- After excluding this rater, we had adequate global fit to the Rasch model

Results

- A wide range of speakers and raters
- Rater fair score difference = 1.36 (on a scale of 1 to 5)
- Fluency: slightly more difficult

Measr	+Ss	-Rater	-Criteria	S.1	S.2	S.3	S.4	S.5	
3	+ *****	+	+	+	(5)	+	(5)	+	(5)
	**								
2	+ *	+	+	+	4	+	4	+	4
	****	*							
	**	**							
	*	*							
1	+ ***	+	+	+	---	+	---	+	---
	***	**							
	**	***							
		*	AnalyticFluency						
		**							
* 0	* *	* **	* AnalyticGrammar	*	* 3	* 3	* 3	* *	*
	**	*	AnalyticVocabulary	3					3
	*	**							
	*	****							
	**								
-1	+	+	**	+	+	+	---	+	+
	**				---		---		
	*****	***							---
	*								

-2	+	+	+	+	2	+	2	+	2
						2		2	
	**								
-3	+ *****	+	+	+	(1)	+	(1)	+	(1)
Measr	* = 1	* = 1	-Criteria	S.1	S.2	S.3	S.4	S.5	

AnalyticFluency


AnalyticGrammar
AnalyticVocabulary

AnalyticPronunciation

HolisticComprehensibility

Results

- Interrater agreement: Exact = 39.3% > Expected = 39.2%
- Rater separation 8.57. Strata 11.76.
- A wide difference in rater severity: beyond ± 1 logits
- 4 very severe raters and 3 very lenient raters
 - Need some adjustments?
- A model rater: -0.30 (Infit mean squares = 0.74)
 - Most raters were stricter and had more score variations than the model rater.
- No overfitting rater but **1 underfitting rater**: Infit MS = 1.59
 - Low proficiency and low familiarity to Japanese accents?



Bias analysis

- Student x rater: 96 bias cases (7.44%)
 - 24 raters out of 26 showed biases. 43 students out of 50 had biases.
- Student x criterion: 9 cases (3.60%)
 - 7 students 3 criteria
- Rater x criterion: 16 cases (12.31%)
 - 7 raters 5 criteria (all criteria)
- Limited bias in assessing comprehensibility, but overall systematic bias
 - Difficult to interpret why we had certain biases

Using the rubric, raters reliably evaluated L1 Japanese students' L2 comprehensibility

- Raters highly reliably differentiated audio files into different levels
 - pilot study revealed consistent yet significant variations
 - rater training minimized the impact of sources of variance?
- Rating rubric (Isaacs et al., 2018) functioned in EFL context:
 - ESL (Canada/UK) EAP teachers vs. EFL (Japan) EAP teachers
 - Mixed L1 university students vs. L1 Japanese secondary school students
 - Several speaking tasks versus short extemporaneous speech

Implications

- Trained raters reliably evaluated L2 comprehensibility + 4 criteria across levels
 - brief online training feasible for teachers
 - scores can be provided to students/teachers as feedback ⇒ possible use as formative assessment (with score report + interpretation)
- Japanese-translated material functioned adequately
 - potential to be applied to other L1 contexts

Limitations and future directions

- **Rater sampling:** highly motivated and experienced in scoring
 - novice teachers may show greater variability in ratings (Kermad, 2024)
 - for generalization: include teacher training workshops, pre-service programs, and non-L1 Japanese-speaking teachers (e.g., assistant language teachers)?
- **Task characteristics:** materials and files from the same corpus
 - *note:* training and target files used different topics
 - need to explore whether revised rubric applies across different speaking tasks and/or speaker groups in classroom settings

Summary

While raters may not be representative, the rubrics can be used by teacher-raters to assess comprehensibility of low-proficiency L2 English learners.

Selected references

Derwing, T. M. & Munro, M. J. (2015). *Pronunciation fundamentals: Evidence-based perspectives for L2 teaching and research*. John Benjamins Publishing Company.

Munro, M. J. & Derwing, T. M. (1995). Foreign accent, comprehensibility, and intelligibility in the speech of second language learners. *Language Learning*, 45, 73–97.

Isaacs, T., Trofimovich, P. & Foote, J. A. (2018). Developing a user-oriented second language comprehensibility scale for English-medium universities. *Language Testing*, 35, 193–216.

Isaacs, T. & Trofimovich, P. (2012). Deconstructing comprehensibility: Identifying the linguistic influences on listeners' L2 comprehensibility ratings. *Studies in Second Language Acquisition*, 34, 475–505.

Kahng, J. (2018). The effect of pause location on perceived fluency. *Applied Psycholinguistics*, 39, 569–591.

Kang, O., Rubin, D. & Kermad, A. (2019). The effect of training and rater differences on oral proficiency assessment. *Language Testing*, 36, 481–504.

Knoch, U., Deygers, B. & Khamboonruang, A. (2021). Revisiting rating scale development for rater-mediated language performance assessments: Modelling construct and contextual choices made by scale developers. *Language Testing*, 38, 602–626.

Saito, K. & Plonsky, L. (2019). Effects of second language pronunciation teaching revisited: A proposed measurement framework and meta-analysis. *Language Learning*, 69, 652–708.

Acknowledgements

- This work was supported by JSPS KAKENHI Grant Number: 24K00082
- Research assistants:
 - Junko Sekine
 - Rika Yoshizaki
 - Kengo Kikuhara



Contact:

- Aki Tsunemoto (Tohoku University): aki.tsunemoto.a7@tohoku.ac.jp
- Rie Koizumi (University of Tsukuba): koizumi.rie.ge@u.tsukuba.ac.jp